Agro Visible: dados coletados e features da LSTM

Relatório técnico gerado em 21/10/2026 a partir de **src/models/dataset.py** e **src/features/build_features.py**. Dataset: **data/processed/dataset_diario.csv**, 5169 linhas (dias úteis com indicador CEPEA), 07/12/2005 a 31/08/2026.

1. Resumo

26 features, todas estacionárias ou limitadas por construção, organizadas em 7 grupos. Entrada da rede: janela de **63 dias úteis** × 26 features. Alvo: log-retorno futuro do indicador CEPEA arábica (**cepea_arabica_brl_sc**) em **21, 63, 126 dias úteis** (cerca de 1, 3 e 6 meses), $y_h(t) = \ln P(t+h) - \ln P(t)$. Normalização: StandardScaler ajustado apenas no treino (até 30/06/2022) e aplicado a validação e teste; não há normalização em janela deslizante. Não há lags explícitos além dos que a janela de 63 dias fornece. Alinhamento: calendário de dias úteis do CEPEA; fontes de menor frequência preenchidas com o último valor conhecido (ffill), nunca com valores futuros. COT e Pink Sheet são ancorados na data de divulgação, não na de referência.

2. Dados brutos coletados (data/raw)

Arquivos como saem da coleta (python -m src.data.collect), antes de qualquer alinhamento ou transformação. Período e estatísticas calculados sobre o arquivo atual; n = observações não nulas.

cepea_cafe.csv · 7470 linhas · 02/09/1996 a 31/08/2026 · frequência: diária (dias úteis BR)

Fonte: CEPEA/ESALQ, indicadores de café arábica (tipo 6, bebida dura, posto SP) e robusta (ES). Download manual dos XLS do site (bloqueia scraping); módulo src/data/cepea.py.

Coluna	Conteúdo	n	Média	Mín.	Máx.
cepea_arabica_brl_sc	indicador arábica, R$/saca 60 kg	7470	515.5	101.5	2.769
cepea_arabica_usd_sc	indicador arábica, US$/saca	7470	156.3	30.92	480.8
cepea_robusta_brl_sc	indicador robusta, R$/saca	6136	406.4	48.5	2.102
cepea_robusta_usd_sc	indicador robusta, US$/saca	6136	112.2	19.7	363.9

market_yahoo.csv · 6883 linhas · 03/01/2000 a 01/09/2026 · frequência: diária (pregões ICE)

Fonte: Yahoo Finance via yfinance; fechamento ajustado. KC=F = contrato contínuo Coffee C (ICE NY). BRL=X coletado mas não usado (PTAX oficial substitui).

Coluna	Conteúdo	n	Média	Mín.	Máx.
ice_arabica_cents_lb	futuro Coffee C, primeiro vencimento, cents de US$/lb	6685	147	41.5	438.9
usd_brl_yahoo	câmbio USD/BRL intradiário Yahoo (não usado)	5485	3.418	1.534	6.3

ice_curve.csv · 745 linhas · 02/10/2023 a 14/09/2026 · frequência: diária, desde out/2023

Fonte: Yahoo Finance, contratos individuais KC{H,K,N,U,Z}yy.NYB; acumulado a cada coleta porque o Yahoo descarta vencidos. Módulo src/data/futures_curve.py. Usado só no motor de hedge, não na LSTM.

Coluna	Conteúdo	n	Média	Mín.	Máx.
KCU26	fechamento de cada vencimento, cents/lb (uma coluna por contrato)	744	261.8	156.9	377.8
KCZ26	fechamento de cada vencimento, cents/lb (uma coluna por contrato)	680	261.6	180.7	346.2
KCH27	fechamento de cada vencimento, cents/lb (uma coluna por contrato)	618	264	187.1	339.9
KCK27	fechamento de cada vencimento, cents/lb (uma coluna por contrato)	574	264.9	200.6	334.6
KCN27	fechamento de cada vencimento, cents/lb (uma coluna por contrato)	534	265.2	199.4	329.2
KCU27	fechamento de cada vencimento, cents/lb (uma coluna por contrato)	491	265.5	198.7	326
KCZ27	fechamento de cada vencimento, cents/lb (uma coluna por contrato)	428	269.3	200.4	325.1
KCH28	fechamento de cada vencimento, cents/lb (uma coluna por contrato)	366	271.6	223.4	324.5

macro_bcb.csv · 9741 linhas · 01/01/2000 a 01/09/2026 · frequência: diária (PTAX em dias úteis; Selic em calendário civil)

Fonte: Banco Central do Brasil, API SGS via python-bcb (séries 1 e 432), em blocos de 9 anos.

Coluna	Conteúdo	n	Média	Mín.	Máx.
ptax_venda	taxa de câmbio PTAX venda, R$/US$	6698	3.231	1.534	6.209
selic_meta	meta Selic definida pelo Copom, % a.a.	9741	12.43	2	26.5

clima_openmeteo.csv · 9735 linhas · 01/01/2000 a 26/08/2026 · frequência: diária (calendário civil)

Fonte: Open-Meteo Archive API (reanálise ERA5), 4 pontos: Varginha (-21,55; -45,43), Patrocínio (-18,94; -46,99), Franca (-20,54; -47,40), Colatina (-19,54; -40,63). Módulo src/data/clima.py.

Coluna	Conteúdo	n	Média	Mín.	Máx.
tmin_sul_minas	temperatura mínima a 2 m, °C, por região	9735	15.53	2.6	22.2
tmin_cerrado_mg	temperatura mínima a 2 m, °C, por região	9735	16.91	5.1	24.1
tmin_mogiana	temperatura mínima a 2 m, °C, por região	9735	16.25	3	23.4
tmin_es_robusta	temperatura mínima a 2 m, °C, por região	9735	20.28	10.6	26.2
prec_sul_minas	precipitação acumulada no dia, mm, por região	9735	3.294	0	155.6
prec_cerrado_mg	precipitação acumulada no dia, mm, por região	9735	3.557	0	140.5
prec_mogiana	precipitação acumulada no dia, mm, por região	9735	3.639	0	81.3
prec_es_robusta	precipitação acumulada no dia, mm, por região	9735	2.344	0	118.3

cot_cftc.csv · 1337 linhas · 07/01/2000 a 28/08/2026 · frequência: semanal

Fonte: CFTC, relatório Commitments of Traders (legacy, futures only) via cot-reports, filtrado em COFFEE C. report_date = terça de referência; available_date = +3 d.u. (sexta de divulgação), usado no merge.

Coluna	Conteúdo	n	Média	Mín.	Máx.
noncomm_long	contratos comprados por non-commercials (fundos)	1337	43.498	3.729	98.292
noncomm_short	contratos vendidos por non-commercials	1337	31.202	1.073	161.882
open_interest	contratos em aberto	1337	161.276	39.206	356.646
cot_net_noncomm	long - short	1337	12.296	-98.481	76.520
cot_net_pct_oi	(long - short) / open interest	1337	0.07264	-0.2994	0.401

insumos_pinksheet.csv · 312 linhas · 03/02/2000 a 05/01/2026 · frequência: mensal

Fonte: Banco Mundial, Commodity Markets (Pink Sheet) mensal, planilha CMO-Historical-Data-Monthly.xlsx. month = mês de referência; available_date = 3 d.u. após o fim do mês. DAP e KCl coletados mas não usados.

Coluna	Conteúdo	n	Média	Mín.	Máx.
urea_usd_ton	ureia, US$/t	312	290.9	77.4	925
dap_usd_ton	fosfato diamônico, US$/t (não usado)	312	398.1	133.1	1.076
kcl_usd_ton	cloreto de potássio, US$/t (não usado)	312	304.6	112.5	1.202
crude_usd_bbl	petróleo bruto, média Brent/WTI/Dubai, US$/barril	312	65.02	18.52	132.8

data/external (arquivos manuais, não gerados pela coleta)

Arquivo	Conteúdo
cepea-consulta-{diaria,mensal,anual}-{arabica,robusta}-{1986,2006}.xls	XLS originais do CEPEA (origem de cepea_cafe.csv)
conab_serie_historica_custos_cafe_arabica_2003a2025.xls	CONAB/GECUP, série histórica de custos de produção do café arábica por município e ano
conab_coe_cot_cafe_arabica_mg.csv	extração: COE (custo variável), COT (custo operacional) e CT (custo total), R$/saca, Guaxupé, Patrocínio, Manhuaçu, Três Pontas, Franca

3. Alinhamento (src/features/build_features.py)

Os brutos são unidos num calendário diário a partir de 08/11/2001 (início do robusta). As features de clima são calculadas ainda no calendário civil. Em seguida o dataset é recortado para os dias com indicador CEPEA arábica (dias úteis brasileiros) e as demais fontes são preenchidas com o último valor conhecido (ffill). COT e Pink Sheet entram pela data de divulgação, não pela de referência. Depois das médias móveis de 504 dias e dos retornos de 252 dias dos insumos, o dataset efetivo começa em 07/12/2005. O futuro ICE é convertido para R$/saca por cents/lb ÷ 100 × 132,277 × PTAX.

4. Features por grupo

Retornos logarítmicos · fonte: Yahoo Finance (KC=F), CEPEA/ESALQ, BCB PTAX

Feature	Definição	Frequência
ret_arabica_1d	ln P(t) - ln P(t-1) do indicador CEPEA arábica (R$/sc)	diária
ret_arabica_21d	ln P(t) - ln P(t-21), retorno de ~1 mês	diária
ret_robusta_1d	log-retorno diário do indicador CEPEA robusta (R$/sc)	diária
ret_ice_1d	log-retorno diário do futuro Coffee C (ICE NY, cents/lb)	diária
ret_ptax_1d	log-retorno diário da PTAX venda	diária

Posição do preço vs. médias móveis · fonte: CEPEA/ESALQ

Feature	Definição	Frequência
preco_vs_ma_1m	P / média móvel 21 d - 1	diária
preco_vs_ma_3m	P / média móvel 63 d - 1	diária
preco_vs_ma_1a	P / média móvel 252 d - 1	diária
preco_vs_ma_2a	P / média móvel 504 d - 1	diária

Mercado · fonte: CEPEA, ICE via Yahoo, BCB

Feature	Definição	Frequência
vol_21d	desvio-padrão dos retornos diários em 21 d, anualizado (× raiz(252))	diária
spread_arabica_robusta	P arábica / P robusta (ambos CEPEA, R$/sc)	diária
base_fisico_futuro_pct	(P físico - F) / F, com F = ICE cents/lb ÷ 100 × 132,277 × PTAX (R$/sc)	diária

Calendário e macro · fonte: calendário; BCB SGS 432

Feature	Definição	Frequência
mes_sin	sen(2·pi · mês / 12)	diária
mes_cos	cos(2·pi · mês / 12)	diária
bienalidade_alta	dummy = 1 se ano-safra par (2020, 2022, 2024…): carga cheia no Brasil; ano-safra começa em julho	diária
selic_meta	meta Selic do Copom, % a.a.	diária (ffill)

Clima nas regiões produtoras · fonte: Open-Meteo (ERA5): Varginha, Patrocínio, Franca, Colatina

Feature	Definição	Frequência
chuva_arabica_30d	precipitação acumulada 30 d, média de Sul de Minas, Cerrado e Mogiana (mm)	diária, calendário civil
chuva_arabica_90d	idem, 90 d	diária, calendário civil
tmin_arabica_7d	mínima das temperaturas mínimas em 7 d nas três regiões (°C)	diária
geada_30d	dummy = 1 se Tmin < 3 °C entre maio e setembro em algum dos últimos 30 d	diária
chuva_robusta_90d	precipitação acumulada 90 d em Colatina, ES (mm)	diária, calendário civil

Posicionamento de fundos (COT/CFTC) · fonte: CFTC via cot-reports, ancorado na data de divulgação

Feature	Definição	Frequência
cot_net_pct_oi	(long - short) non-commercial / open interest, Coffee C	semanal (ffill)
cot_net_pct_oi_chg4w	variação de cot_net_pct_oi em 20 dias úteis	semanal (ffill)

Insumos agrícolas · fonte: Banco Mundial Pink Sheet, disponível 3 d.u. após o fim do mês

Feature	Definição	Frequência
indice_troca_urea	(ureia US$/t × PTAX) / P arábica: sacas para comprar 1 t de ureia	mensal (ffill)
ret_urea_1a	ln ureia(t) - ln ureia(t-252)	mensal (ffill)
ret_crude_1a	ln petróleo(t) - ln petróleo(t-252)	mensal (ffill)

5. Estatísticas descritivas das features no treino (07/12/2005 a 30/06/2022)

Valores brutos antes da padronização. Média e desvio são os parâmetros do StandardScaler.

Feature	Média	Desvio	Mín.	Máx.
ret_arabica_1d	0.0004229	0.01474	-0.1024	0.08273
ret_arabica_21d	0.008516	0.07229	-0.2437	0.3892
ret_robusta_1d	0.0003575	0.00926	-0.07534	0.04352
ret_ice_1d	0.0002239	0.01997	-0.1109	0.1179
ret_ptax_1d	0.0002123	0.009722	-0.09215	0.08917
preco_vs_ma_1m	0.004499	0.04044	-0.1379	0.2334
preco_vs_ma_3m	0.0138	0.07352	-0.1747	0.4993
preco_vs_ma_1a	0.05506	0.1647	-0.2385	0.6743
preco_vs_ma_2a	0.1034	0.2475	-0.3273	1.078
vol_21d	0.2174	0.08423	0.07283	0.6448
spread_arabica_robusta	1.455	0.2825	0.9602	2.563
base_fisico_futuro_pct	-0.1883	0.04981	-0.3673	-0.0233
mes_sin	0.005724	0.7064	-1	1
mes_cos	-0.01616	0.7078	-1	1
bienalidade_alta	0.4823	0.4997	0	1
selic_meta	9.919	3.577	2	18.5
chuva_arabica_30d	104.8	99.13	0	461.4
chuva_arabica_90d	318.5	249.2	2.733	965.1
tmin_arabica_7d	13.57	3.529	3	20.2
geada_30d	0	0	0	0
chuva_robusta_90d	199	162.2	8.6	744.3
cot_net_pct_oi	0.07379	0.1477	-0.2959	0.3291
cot_net_pct_oi_chg4w	0.0007715	0.06753	-0.1843	0.2459
indice_troca_urea	2.1	0.7376	0.6941	6.797
ret_urea_1a	0.06771	0.4101	-1.218	1.302
ret_crude_1a	0.03094	0.3896	-1.181	1.149

6. Observações de engenharia

• O alvo é o log-retorno, não o nível de preço: evita que a rede aprenda a não-estacionariedade da série; o preço é reconstruído por $P(t+h) = P(t)\cdot\exp(y_h \text{ previsto})$.
• A base físico × futuro é modelada em percentual do futuro porque em reais ela escala com o nível de preço.
• As features de clima são calculadas no calendário civil completo antes do recorte para dias úteis, para não perder chuva de fins de semana e feriados.
• O início efetivo do dataset (dez/2005) decorre das médias móveis de 504 dias e dos retornos de 252 dias dos insumos.
• Ablação (reports/experimentos/c3_ablacao.csv): remover mercado ou calendário/Selic piora o erro de 126 dias em 10–12 %; remover retornos/médias móveis, COT ou insumos melhora o erro, o que indica sobreajuste do modelo completo e candidatos a poda.
• **Achado: geada_30d é constante igual a zero em toda a série** (2005–2026). A reanálise ERA5 nos quatro pontos de grade nunca registra Tmin abaixo de 3 °C entre maio e setembro (mínimo de 3,0 °C em 2021); o StandardScaler deixa a coluna com escala 1 e ela não contribui para o modelo. A geada de julho de 2021, que o split de treino deveria conter, não aparece. Correções possíveis: limiar de 5 °C ou anomalia de Tmin em relação à climatologia do dia, ambos a validar na ablação.
• Pendentes, discutidos mas não implementados: estoques certificados ICE, estimativas de safra CONAB, balanço USDA/ICO, exportações Cecafé, anomalia climática por fase fenológica e retorno implícito na curva de futuros

como feature.